

BUT Science des Données – Semestre 2
SAÉ – Échantillonnage et Estimation

Échantillonnage, Estimation et Traitement de données d'enquête

Population des communes de Bretagne – Insee, Recensement 2020
Enquête sport étudiants – IUT de Niort, 2024

DE MATHA Manon
RENARD Louis

Année universitaire 2025–2026

Partie 1 : Estimation du nombre d'habitants d'une région de France

L'objectif est d'estimer le nombre total d'habitants en Bretagne à partir d'un échantillonnage de communes, en comparant deux méthodes de sondage (échantillonnage aléatoire simple et stratifié). Pour réaliser les estimations, nous avons utilisé des intervalles de confiance (IDC) et le calcul de leur marge d'erreur. Pour vérifier la fiabilité de cette technique, nous avons procédé à 10 échantillonnages par méthode, que nous avons comparés aux données réelles.

1.0 Préparation des données

1.0.1 Installations et chargement des librairies

Après récupération du jeu de données « population_francaise_communes.xlsx », nous avons récupéré les données (sans les lignes descriptives) afin de les stocker dans un fichier CSV.

Avant toute action de traitement, nous avons défini le répertoire de travail avec l'instruction `setwd`. De plus, nous avons besoin de la librairie `sampling`, d'où son importation.

```
setwd("E:/IUT NIORT/L1/S2/SAE/Echantillonnage et estimation")

library(sampling)
```

1.0.2 Importation et préparation des données

Nous avons ensuite importé le jeu de données préalablement converti en CSV et nettoyé des lignes informatives. Puisque notre population est « l'ensemble des communes de Bretagne », nous n'avons conservé que les données de cette région. Pour plus de lisibilité, nous n'avons gardé que les colonnes portant des informations exploitables : le code département, le nom de la commune et sa population. Afin de vérifier que l'opération de filtrage s'est passée comme prévu, nous utilisons la fonction `head()` pour afficher les 6 premières lignes de la table.

```
donnees <- read.csv2("donnees.csv")

donnees <- donnees[donnees$Nom.de.la.region == "Bretagne",
                  c("Code.département", "Commune", "Population.totale")]

head(donnees)
```

1.0.3 Définition de la population et du total réel

Nous avons isolé les noms des communes pour pouvoir effectuer ultérieurement le tirage. Nous avons également extrait le nombre de communes (1 207) et, avec la fonction agrégative `sum()`, calculé le nombre total d'habitants en Bretagne. C'est ce nombre que nous cherchons à estimer. La population réelle est de 3 463 439 habitants (recensement 2020).

```
U <- donnees$Commune

N_total <- length(U)
N_total # 1207

T_reel <- sum(donnees$Population.totale)
T_reel # 3463439
```

1.1 Échantillonnage aléatoire simple

1.1.1 Choix de la taille d'échantillon

Nous avons fixé la taille de l'échantillon à $n = 100$, soit environ 1/12 de notre population. En gardant la même taille, nous répétons le tirage 10 fois pour mesurer la fiabilité de notre méthode d'estimation. Les résultats sont stockés dans un data frame initialisé avant la boucle, contenant la population totale, l'estimation, les bornes de l'IDC et la marge d'erreur.

```
n <- 100

resultIDC <- data.frame(Pop.Total = c(), Test = c(),
                        idc_T1 = c(), idc_T2 = c(),
                        marge.erreur = c())
```

1.1.2 Tirage de l'échantillon

Nous créons une boucle avec 10 itérations. À chaque tour, nous tirons un échantillon de taille $n = 100$ parmi l'ensemble des communes avec la fonction `sample()`. Il nous suffit ensuite d'extraire cet échantillon de notre table de données grâce à la syntaxe des data frames R.

```
for (i in 1:10) {

  E <- sample(U, n)

  donnees1 <- donnees[donnees$Commune %in% E, ]
```

1.1.3 Estimation de la population totale et IDC

Nous calculons ensuite le nombre moyen d'habitants dans les communes de notre échantillon avec la fonction `mean()`. De plus, nous calculons un IDC à 95 % de la moyenne avec `t.test()`. Une fois cela fait, nous multiplions la moyenne par le nombre total de communes (N_{total}) pour obtenir une estimation de la population totale. Cette estimation repose sur l'hypothèse que notre échantillon est représentatif de la population : la moyenne de l'échantillon devrait être proche de la moyenne de la population complète.

```
xbar <- mean(donnees1$Population.totale)

idcmoy <- t.test(donnees1$Population.totale)$conf.int

T_est <- N_total * xbar
```

1.1.4 Ajustement de l'IDC et marge d'erreur

Nous multiplions les deux bornes de l'IDC par le nombre total de communes afin d'ajuster l'intervalle de la moyenne à la population totale. Nous calculons ensuite la marge d'erreur (demi-largeur de l'IDC). Enfin, nous créons un data frame temporaire et le fusionnons verticalement avec notre table de résultats.

```
idcT <- idcmoy * N_total

marge <- (idcT[2] - idcT[1]) / 2

resTemp <- data.frame(Pop.Total = T_reel, Test = T_est,
                     idc_T1 = idcT[1], idc_T2 = idcT[2],
                     marge.erreur = marge)

resultIDC <- rbind(resultIDC, resTemp)
```

}

1.1.5 Interprétation des résultats


Voici les résultats obtenus pour les 10 tirages aléatoires simples :

Tableau des résultats — Échantillonnage aléatoire simple

N°	Pop. Totale	Estimation	IDC borne inf.	IDC borne sup.	Marge d'erreur
1	3 463 439	5 290 163	-2 030	10 582 355	5 292 193
2	3 463 439	3 426 392	1 963 457	4 889 327	1 462 935
3	3 463 439	3 801 778	2 146 645	5 456 910	1 655 133
4	3 463 439	3 751 513	2 370 799	5 132 226	1 380 714
5	3 463 439	5 169 735	1 773 057	8 566 413	3 396 678
6	3 463 439	2 731 559	2 216 720	3 246 398	514 839
7	3 463 439	3 539 235	2 296 273	4 782 196	1 242 962
8	3 463 439	6 599 550	909 527	12 289 574	5 690 024
9	3 463 439	3 036 513	2 178 338	3 894 688	858 175
10	3 463 439	3 262 308	2 426 318	4 098 298	835 990

En analysant les résultats, on remarque que la valeur estimée est souvent relativement proche de la valeur réelle, mais avec une marge d'erreur élevée et donc un IDC aux bornes très écartées. On observe même que pour certaines estimations, la borne inférieure de l'IDC peut devenir négative en raison d'une marge d'erreur importante, ce qui suggère un échantillon très dispersé et peu représentatif.

Cette méthode de tirage donne des résultats très variables, dépendant fortement de la représentativité de l'échantillon. Une taille d'échantillon plus élevée permettrait probablement de réduire les marges d'erreur et d'améliorer la précision. Cette méthode, qui repose sur une approche naïve, reste peu fiable pour estimer la population d'une région.



1.2 Échantillonnage aléatoire stratifié

L'objectif de cette seconde méthode est d'améliorer la précision de notre estimation en divisant la population en plusieurs groupes homogènes appelés strates. Nous avons choisi de créer quatre strates en fonction de la population des communes, en nous appuyant sur les quartiles afin de réduire la variance des estimations et de s'assurer que l'échantillon contient des communes de toute taille.

1.2.1 Création des strates et découpage

Nous avons affiché les quartiles de la variable Population.totale avec la fonction `summary()`. Ces quartiles nous permettent de découper la population en 4 groupes de tailles proches. Les bornes retenues sont : 716,5 ; 1 390,0 et 2 761,5 habitants. Nous avons ensuite créé une nouvelle variable « strate » avec la fonction `cut()`. La strate 1 contient les communes les moins peuplées, la strate 4 les plus peuplées.

```
summary(donnees$Population.totale)

donnees$strate <- cut(donnees$Population.totale,
                      breaks = c(0, 716.5, 1390.0, 2761.5, Inf),
                      labels = c(1, 2, 3, 4))
```

1.2.2 Préparation de la table stratifiée

Une fois les strates créées, nous avons trié les données avec `order()` pour obtenir une table stratifiée appelée `datastrat`. Nous avons calculé les effectifs `Nh` de chaque strate avec la fonction `table()`, recompté le nombre total de communes (1 207), et calculé les poids `gh` de chaque strate (proportion de communes par strate). Ces données serviront aux calculs ultérieurs.

```
datastrat <- donnees[order(donnees$strate), ]

Nh <- table(datastrat$strate) # 302, 302, 301, 302
N_total <- sum(Nh)           # 1207
gh <- Nh / N_total           # ~0.25 chacune
```

1.2.3 Tirage stratifié et paramétrage

Comme pour le sondage aléatoire simple, nous avons choisi un échantillon de $n = 100$ communes, réparties proportionnellement entre les strates (environ 25 communes par strate). Nous calculons les effectifs par strate `nh` et le taux de sondage `fh`. Pour le tirage, nous utilisons la fonction `strata()` de la librairie `sampling` avec la méthode « `srswor` » (sondage aléatoire simple sans remise dans chaque strate). Les données tirées sont récupérées avec `getdata()`.

```
n <- 100

for (i in 1:10) {

  nh <- as.integer(round(c(n * Nh[1] / N_total, n * Nh[2] / N_total,
                        n * Nh[3] / N_total, n * Nh[4] / N_total)))

  fh <- nh / Nh

  st <- strata(datastrat, stratanames = c("strate"),
              size = nh, method = "srswor")

  datal <- getdata(datastrat, st)
```

1.2.4 Séparation de l'échantillon et calcul des moyennes

Après le tirage, nous avons séparé l'échantillon en 4 sous-échantillons correspondant aux strates. Pour chacun, nous avons calculé la moyenne et la variance de la population. La moyenne stratifiée $\bar{X}_{\text{barst}}$ est obtenue en pondérant les moyennes par strate par leurs effectifs N_h , divisé par le nombre total de communes. Cela permet de prendre en compte le poids réel de chaque strate dans la population.

```
ech1 <- data1[data1$strate == 1, ]
ech2 <- data1[data1$strate == 2, ]
ech3 <- data1[data1$strate == 3, ]
ech4 <- data1[data1$strate == 4, ]

m1 <- mean(ech1$Population.totale) # idem m2, m3, m4
var1 <- var(ech1$Population.totale) # idem var2, var3, var4

Xbarst <- (Nh[1]*m1 + Nh[2]*m2 + Nh[3]*m3 + Nh[4]*m4) / N_total
```

1.2.5 Variance, IDC et estimation du total

Nous avons calculé la variance estimée de la moyenne stratifiée selon la formule $\text{Var}(\bar{X}_{\text{barst}}) = \sum (g_h^2 \times (1 - f_h) \times \text{Var}_h / n_h)$. Cette variance permet de construire un IDC à 95 % avec la loi normale. L'estimation du total est obtenue en multipliant $\bar{X}_{\text{barst}}$ par N_{total} , et l'IDC est ajusté de la même manière.

```
varXbarst <- (gh[1])^2*(1-fh[1])*var1/nh[1] + ...

alpha <- 0.05
binf <- Xbarst - qnorm(1 - alpha/2) * sqrt(varXbarst)
bsup <- Xbarst + qnorm(1 - alpha/2) * sqrt(varXbarst)

Tstr <- N_total * Xbarst
idcT <- c(binf, bsup) * N_total
marge <- (idcT[2] - idcT[1]) / 2
}
```

1.2.6 Interprétation des résultats


Voici les résultats obtenus pour les 10 tirages stratifiés :

Tableau des résultats — Échantillonnage stratifié

N°	Pop. Totale	Estimation	IDC borne inf.	IDC borne sup.	Marge d'erreur
1	3 463 439	5 242 348	211 404	10 273 293	5 030 944
2	3 463 439	3 267 582	2 245 713	4 289 451	1 021 869
3	3 463 439	3 684 127	2 581 932	4 786 322	1 102 195
4	3 463 439	2 759 902	2 317 983	3 201 821	441 919
5	3 463 439	2 761 333	2 405 554	3 117 111	355 779
6	3 463 439	3 080 360	2 536 165	3 624 554	544 195
7	3 463 439	2 621 089	2 196 554	3 045 624	424 535
8	3 463 439	3 549 582	2 115 589	4 983 576	1 433 993
9	3 463 439	3 269 519	2 662 949	3 876 090	606 570
10	3 463 439	4 294 863	2 707 962	5 881 764	1 586 901

On remarque que les estimations sont plus proches de la réalité grâce au tirage stratifié par rapport au tirage aléatoire simple. Plus important encore, la marge d'erreur a significativement diminué dans la majorité des cas. La stratification rend l'estimation plus fiable en augmentant la représentativité de l'échantillon. Pour améliorer encore la précision, on pourrait augmenter le nombre de strates ou la taille de l'échantillon.

On remarque toutefois un léger biais de sous-évaluation de la population, qui peut être dû au faible nombre d'itérations ou à un effet de la strate 4 (communes les plus peuplées, à forte variance interne).



1.3 Amélioration : stratification par déciles (10 strates)

Avec 4 strates définies par les quartiles, la strate 4 regroupe des communes allant de 2 762 à 226 654 habitants. Cette hétérogénéité interne génère une variance élevée qui se répercute sur la marge d'erreur. Pour réduire cet effet, nous avons testé un découpage en 10 strates basé sur les déciles de la variable Population.totale.

1.3.1 Découpage en déciles

Les déciles sont calculés avec la fonction `quantile()`. On obtient 10 groupes de ~120 communes chacun, bien plus homogènes que les 4 strates précédentes. En particulier, la dernière strate ne contient plus que les communes de plus de ~6 000 habitants, ce qui réduit considérablement sa variance interne.

```
deciles <- quantile(donnees$Population.totale, probs = seq(0, 1, 0.1))

donnees$strate10 <- cut(donnees$Population.totale,
  breaks = deciles,
  labels = 1:10,
  include.lowest = TRUE)

datastrat10 <- donnees[order(donnees$strate10), ]
Nh10 <- table(datastrat10$strate10)
gh10 <- Nh10 / N_total
```

1.3.2 Tirage et estimation

Le processus est identique à la section 1.2 mais généralisé à 10 strates. Pour calculer la moyenne et la variance de chaque strate, nous parcourons les niveaux de strate dans une boucle for : à chaque itération, on isole le sous-échantillon correspondant et on stocke la moyenne et la variance dans des vecteurs. Les calculs globaux (moyenne stratifiée et sa variance) sont ensuite effectués en dehors de la boucle, en utilisant les vecteurs accumulés. Un ajustement d'arrondi est nécessaire pour que la somme des effectifs par strate fasse exactement 100.

```
nh10 <- as.integer(round(n * Nh10 / N_total))

strates <- levels(datastrat10$strate10)
moyennes <- c()
variances <- c()
for (s in strates) {
  ech_s <- data10[data10$strate10 == s, ]
  moyennes[s] <- mean(ech_s$Population.totale)
  variances[s] <- var(ech_s$Population.totale)
}

Xbarst10 <- sum(Nh10 * moyennes) / N_total
varXbarst10 <- sum((gh10)^2 * (1 - fh10) * variances / nh10)
```

1.3.3 Interprétation


Voici les résultats obtenus pour les 10 tirages avec stratification par déciles :

Tableau des résultats — Échantillonnage stratifié (10 strates)

N°	Pop. Totale	Estimation	IDC borne inf.	IDC borne sup.	Marge d'erreur
1	3 463 439	3 177 527	2 741 090	3 613 965	436 438
2	3 463 439	2 795 089	2 553 850	3 036 329	241 240
3	3 463 439	3 212 594	2 031 916	4 393 272	1 180 678
4	3 463 439	3 111 314	2 729 494	3 493 134	381 820
5	3 463 439	3 144 226	2 815 718	3 472 734	328 508
6	3 463 439	2 968 129	2 593 910	3 342 347	374 219
7	3 463 439	3 596 704	2 748 171	4 445 237	848 533
8	3 463 439	6 261 144	1 347 813	11 174 476	4 913 332
9	3 463 439	3 292 205	2 393 247	4 191 163	898 958
10	3 463 439	2 950 768	2 623 507	3 278 029	327 261

Les résultats avec 10 strates montrent généralement une amélioration par rapport aux 4 strates : la majorité des estimations sont proches de la valeur réelle (entre 2,8 et 3,6 millions) avec des marges d'erreur souvent inférieures à 500 000. On observe cependant un tirage aberrant (n°8 : estimation à 6,3 millions, marge de 4,9 millions), lié à la dernière strate qui contient les grandes villes avec une forte dispersion. Ce cas illustre la limite d'une stratification fine avec un petit nombre de communes par strate (~10) : la variance intra-strate est plus difficile à estimer de manière fiable.

Malgré ce cas extrême, les résultats sont dans l'ensemble meilleurs qu'avec 4 strates. Le compromis optimal serait d'augmenter la taille de l'échantillon conjointement au nombre de strates, afin de garantir suffisamment de communes dans chaque groupe.



1.4 Exportation des résultats

Les résultats sont exportés au format CSV pour exploitation dans Excel (tableaux et graphiques). Ce format est privilégié pour sa portabilité et le fait qu'il ne nécessite pas de logiciel spécialisé.

```
write.csv2(resultIDC, "res_IDC1.csv")
write.csv2(resultIDC2, "res_IDC2.csv")
write.csv2(resultIDC3, "res_IDC3.csv")
```

1.5 Conclusion

En mettant en pratique les outils statistiques vus en cours, nous sommes capables d'estimer la population d'une région en nous appuyant sur l'estimation des moyennes. C'est un outil puissant car il permet d'estimer une population que l'on ne pourrait pas compter de manière exhaustive. Grâce aux IDC, on peut mesurer la précision de nos estimations et faire varier le niveau de confiance.

Nous avons également pu comparer trois approches : le sondage aléatoire simple (s.a.s.), le sondage stratifié par quartiles (4 strates) et le sondage stratifié par déciles (10 strates). Le sondage stratifié produit des estimations plus précises avec des marges d'erreur réduites, car il garantit une meilleure représentativité de l'échantillon. L'augmentation du nombre de strates (de 4 à 10) permet de réduire encore la variance intra-strate, au prix d'un nombre de communes plus faible par strate. Découvrir les facteurs qui influencent la précision fait également partie des acquis de ce projet.

Partie 2 : Traitement de données d'enquête

1. Introduction

Cette partie porte sur l'analyse statistique des données issues d'une enquête réalisée auprès des étudiants de l'IUT de Niort sur leur pratique sportive. L'objectif est de déterminer s'il existe des relations significatives entre la variable « sport » (Oui/Non) et d'autres variables qualitatives du jeu de données, à l'aide du test d'indépendance du khi-deux et du V de Cramer.

2. Importation et aperçu des données

2.1 Conversion et vérification du fichier

Le fichier Excel « EnqueteSportEtudiant2024.xlsx » a d'abord été converti manuellement au format CSV depuis Excel, puis ouvert avec le Bloc-notes afin de vérifier la structure du fichier : séparateur point-virgule, décimale virgule, présence des en-têtes de colonnes en première ligne, et cohérence générale des données.

2.2 Importation dans R

Le fichier CSV est ensuite importé dans R avec la fonction `read.csv2()`, en précisant le séparateur, la décimale et la présence d'en-têtes. Les cellules vides sont automatiquement interprétées comme des valeurs manquantes (NA).

```
setwd("E:/IUT NIORT/L1/S2/SAE/Echantillonnage et estimation")

sport <- read.csv2("EnqueteSportEtudiant2024.csv",
                  sep=";", dec=",", header = TRUE)
```

2.3 Aperçu des données

La commande `head()` affiche les 6 premières lignes, et `str()` détaille la structure complète du jeu de données.

```
head(sport)
str(sport)
dim(sport)
```

Résultat : le jeu de données contient **375 individus** (étudiants) et **76 variables**. Toutes les variables sont de type `character` (qualitatives), à l'exception de quelques colonnes entièrement vides (`logical`).

3. Choix des variables pour le croisement

Le questionnaire comporte 76 variables, mais toutes ne peuvent pas être croisées avec « sport ». Plusieurs catégories de variables ont été exclues :

3.1 Variables exclues : questions ouvertes

Les variables de type texte libre (`deptgeo_Autre`, `logement_Autre`, `raisonnonsuaps_Autre`, `typessportavant_Autre`, `raisonarretsport_Autre`, `motiv_Autre`, `argument_Autre`, etc.) ne peuvent pas être utilisées dans un test du khi-deux. Elles contiennent des réponses uniques et non catégorisables directement (par exemple « salle de sport », « déménagement », « judo boxe mma »). Un recodage serait nécessaire mais sortirait du cadre de l'exercice.

3.2 Variables exclues : variables conditionnelles (sous-populations)

Le questionnaire comporte une structure arborescente : certaines questions ne sont posées qu'aux sportifs, d'autres qu'aux non sportifs. Par exemple :

- **motiv, passersport, compet, heuressuaps, bonif, satisfsuaps** ne sont renseignées que pour les sportifs (sport = « Oui »).
- **raisonnonsuaps, sportavant, raisonarretsport, covid, raisonjamaissport, refairesport, argument** ne sont renseignées que pour les non sportifs (sport = « Non »).

Si l'on construit un tableau croisé entre « sport » et l'une de ces variables, une ligne entière du tableau sera vide (que des NA). Le test du khi-deux n'a alors aucun sens statistique : on ne peut pas tester l'indépendance entre deux variables quand l'une détermine entièrement la présence ou l'absence de l'autre.

3.3 Variables exclues : variables à choix multiples éclatées

Les variables `typessportavant_1` à `typessportavant_9`, `sportsuaps_1` à `sportsuaps_7`, `sportsnonsuaps_1` à `sportsnonsuaps_9`, `lieu_1` à `lieu_3`, et `raisonnonsatisfsuaps_1` à `raisonnonsatisfsuaps_4` sont des colonnes éclatées issues de questions à choix multiples. Chaque colonne contient une modalité différente pour chaque individu, ce qui rend le croisement direct avec « sport » inadapté.

3.4 Variable recodée : `deptgeo` → `region`

La variable `deptgeo` (département géographique d'origine) contient de nombreuses modalités (79, 17, 85, 86, Autre, etc.) avec des effectifs très faibles pour certaines. Le test du khi-deux serait peu fiable avec autant de cellules à effectifs < 5.

Pour pouvoir tout de même exploiter cette information géographique, nous avons créé une nouvelle variable « `region` » en regroupant les départements de l'ancienne région Poitou-Charentes (16 – Charente, 17 – Charente-Maritime, 79 – Deux-Sèvres, 86 – Vienne) sous la modalité « Poitou-Charentes », et tous les autres sous « Autre ». Ce regroupement est pertinent car l'IUT se situe à Niort (79) : il permet de tester si le fait d'être originaire de la région locale influence la pratique sportive.

Lorsque `deptgeo` vaut « Autre », on consulte la variable `deptgeo_Autre` pour récupérer le véritable département et le classer correctement.

```
sport$region <- ifelse(
  sport$deptgeo %in% c("16", "17", "79", "86") |
  (!is.na(sport$deptgeo_Autre) &
   sport$deptgeo_Autre %in% c("16", "17", "79", "86")),
  "Poitou-Charentes", "Autre"
)
```

On obtient 226 étudiants originaires de Poitou-Charentes et 149 d'ailleurs.

3.5 Condition du khi-deux non valide

La variable `logement` n'est pas retenue. En effet, la modalité « Autre » ne compte que 8 individus (1 non-sportif et 7 sportifs), ce qui génère des effectifs théoriques inférieurs à 5. R affiche d'ailleurs un avertissement lors du test. Les conditions de validité du test du khi-deux ne sont donc pas remplies pour cette variable.

3.6 Variables retenues

Finalement, 13 variables qualitatives sont renseignées pour l'ensemble (ou la quasi-totalité) des 375 individus et se prêtent à un croisement avec « sport » :

sexe, deptformation, niveau, reprise, alternant, bourse, travail, fumer, alimentation, sante, fan, reussite, region.

Note : les variables bourse et travail ne sont renseignées que pour les non-alternants (les alternants n'ont pas répondu à ces questions). Le test du khi-deux exclut automatiquement les NA, donc les effectifs pour ces deux variables sont réduits (234 individus au lieu de 375). Cela ne pose pas de problème pour le test, mais il faut le garder à l'esprit dans l'interprétation.

4. Tableaux croisés

On construit les 13 tableaux croisés entre « sport » et chaque variable retenue à l'aide de la fonction `table()`. La fonction `table()` gère correctement les variables de type character, il n'est pas nécessaire de les convertir en facteur au préalable.

```
TCD_sexe <- table(sport$sport, sport$sexe)
TCD_deptformation <- table(sport$sport, sport$deptformation)
TCD_niveau <- table(sport$sport, sport$niveau)
# ... (idem pour les 10 autres variables)
TCD_region <- table(sport$sport, sport$region)
```

Voici les tableaux croisés des variables dont le test du khi-deux est significatif :

Tableau croisé : sport × sexe

sport \ sexe	Un homme			Une femme		
Non	48	62,5	3,4	43	28,5	7,4
Oui	209	194,5	1,1	74	88,5	2,4

*Effectifs réels

*Effectifs théoriques

*Contributions au K^2

Tableau croisé : sport × deptformation

sport \ dept.	GEA			HSE			SD		
Non	48	33,5	6,2	16	27,9	5,1	27	29,6	0,2
Oui	88	102,4	2,0	97	85,1	1,7	93	90,4	0,1

Tableau croisé : sport × fan

sport \ fan	Non			Oui		
Non	72	36,3	35,2	19	54,7	23,3
Oui	77	112,7	11,3	206	170,3	7,5

Tableau croisé : sport × alimentation

sport \ alim.	Non			Oui		
Non	46	30,9	7,4	45	60,1	3,8
Oui	81	96,1	2,4	202	186,9	1,2

Tableau croisé : sport × réussite

sport \ réussite	Moyennement			Pas vraiment			Tout à fait		
Non	39	27,1	5,2	9	6,8	0,7	41	55,1	3,6
Oui	73	84,9	1,7	19	21,2	0,2	187	172,8	1,2

Tableau croisé : sport × region

sport \ region	Autre			Poitou-Charentes		
Non	30	36,3	1,1	61	54,7	0,7
Oui	119	112,7	0,3	164	170,3	0,2

Tableau croisé : sport × alternant

sport \ alternant	alternant			Non alternant		
Non	69	59,3	1,6	22	31,7	3
Oui	174	183,7	0,5	108	98,3	1

5. Tests du khi-deux d'indépendance

5.1 Principe du test

Le test du khi-deux d'indépendance permet de déterminer si deux variables qualitatives sont liées ou indépendantes. Les hypothèses sont :

H_0 : les deux variables sont indépendantes (aucune relation).

H_1 : il existe une relation significative entre les deux variables.

On fixe le seuil de risque à $\alpha = 0.05$. Si la p-valeur est inférieure à 0.05, on rejette H_0 et on conclut à l'existence d'une relation significative.

5.2 Application

On applique le test à chacun des 13 tableaux croisés :

```

khideux_sexe <- chisq.test(TCD_sexe)
khideux_deptformation <- chisq.test(TCD_deptformation)
khideux_niveau <- chisq.test(TCD_niveau)
khideux_reprise <- chisq.test(TCD_reprise)
khideux_alternant <- chisq.test(TCD_alternant)
khideux_bourse <- chisq.test(TCD_bourse)
khideux_travail <- chisq.test(TCD_travail)
khideux_fumer <- chisq.test(TCD_fumer)
khideux_alimentation <- chisq.test(TCD_alimentation)
khideux_sante <- chisq.test(TCD_sante)
khideux_fan <- chisq.test(TCD_fan)
khideux_reussite <- chisq.test(TCD_reussite)
khideux_region <- chisq.test(TCD_region)

```

5.3 Vérification des conditions de validité

Le test du khi-deux repose sur une approximation qui n'est valide que si tous les effectifs théoriques sont supérieurs ou égaux à 5. On vérifie cette condition avec l'attribut \$expected :

```

khideux_sexe$expected
khideux_deptformation$expected
# ... (idem pour les autres variables)

```

C'est cette vérification qui a conduit à exclure la variable logement (cf. section 3.5) : la modalité « Autre » générerait des effectifs théoriques inférieurs à 5. Pour les 13 variables retenues, tous les effectifs théoriques sont suffisants.

5.4 Tableau des p-valeurs

Pour synthétiser les résultats des 13 tests, on rassemble les informations dans un tableau récapitulatif. On extrait de chaque test la statistique du khi-deux avec `$statistic` (qui mesure l'écart global entre les effectifs observés et théoriques) et la p-valeur avec `$p.value` (qui indique la probabilité d'observer un tel écart sous l'hypothèse d'indépendance). On crée ensuite une colonne de significativité avec `ifelse()` : si la p-valeur est inférieure au seuil de risque $\alpha = 0.05$, le test est significatif. Le tout est regroupé dans un `data.frame` pour un affichage clair.

```

noms_variables <- c("sexe", "deptformation", "niveau", "reprise",
                    "alternant", "bourse", "travail",
                    "fumer", "alimentation", "sante", "fan", "reussite",
                    "region")

p_valeurs <- c(khideux_sexe$p.value, khideux_deptformation$p.value,
               khideux_niveau$p.value, ...)

stats_khi2 <- c(khideux_sexe$statistic, khideux_deptformation$statistic,
                khideux_niveau$statistic, ...)

significatif <- ifelse(p_valeurs < 0.05, "OUI ***", "Non")

tableau_pvaleurs <- data.frame(
  Variable = noms_variables,
  Khi2 = round(stats_khi2, 4),
  P_valeur = round(p_valeurs, 6),
  Significatif = significatif
)
print(tableau_pvaleurs)

```

6. V de Cramer

6.1 Principe

Le V de Cramer mesure l'intensité de la liaison entre deux variables qualitatives. Il se calcule par la formule $V = \sqrt{\chi^2 / (n \times m)}$, où n est l'effectif total et $m = \min(p-1, q-1)$, p et q étant le nombre de modalités de chaque variable. Le V est compris entre 0 (indépendance parfaite) et 1 (liaison parfaite). Par convention, on considère qu'un V inférieur à 0.1 indique une liaison faible, entre 0.1 et 0.3 une liaison modérée, et supérieur à 0.3 une liaison forte.

6.2 Calcul

On définit une fonction pour automatiser le calcul :

```

V_cramer <- function(TCD, resultat_khi2) {
  n <- sum(TCD)
  p <- nrow(TCD)
  q <- ncol(TCD)
  m <- min(p - 1, q - 1)

```

```
V <- sqrt(resultat_khi2$statistic / (n * m))
return(as.numeric(V))
}
```

Le V de Cramer n'est calculé que pour les tests significatifs (p -valeur < 0.05). Pour les tests non significatifs, il n'a pas d'intérêt car on n'a pas rejeté l'hypothèse d'indépendance.

7. Contributions au khi-deux

Pour chaque test significatif, on peut examiner la contribution de chaque cellule au khi-deux total. Cette contribution est obtenue par `$residuals^2` : elle mesure à quel point l'effectif observé dans une cellule s'écarte de ce qu'on attendrait sous l'hypothèse d'indépendance. Plus la valeur est élevée, plus la cellule est responsable de la liaison détectée.

```
khideux_fan$residuals^2
khideux_sexe$residuals^2
# ... (idem pour les autres variables significatives)
```

L'analyse des contributions sera détaillée dans la section 9 (interprétation).

8. Tableau récapitulatif des résultats

Le tableau ci-dessous synthétise l'ensemble des résultats : statistique du khi-deux, p -valeur, risque au seuil 5 %, V de Cramer et intensité de la liaison. Les lignes en vert correspondent aux relations significatives.

Variable	Khi ²	p-valeur	Significatif	V de Cramer	Intensité
sexe	13.3019	0.000265	OUI	0.1886	Modérée
deptformation	15.2853	0.000480	OUI	0.2035	Modérée
niveau	8.1447	0.043114	OUI	0.1478	Modérée
reprise	0.0000	1.000000	Non	—	—
alternant	5.4369	0.019715	OUI	0.1207	Modérée
bourse	1.8808	0.170239	Non	—	—
travail	0.1281	0.720390	Non	—	—
fumer	0.3805	0.537327	Non	—	—
alimentation	13.8016	0.000203	OUI	0.1921	Modérée
sante	0.3093	0.578092	Non	—	—
fan	75.2727	≈ 0	OUI	0.4486	Forte
reussite	12.6614	0.001781	OUI	0.1855	Modérée
region	2.0061	0.156664	Non	—	—

Liaison la plus forte : la variable **fan** présente le V de Cramer le plus élevé (**V = 0.4486**, liaison forte), avec une p -valeur quasi nulle.

9. Interprétation des résultats

9.1 Relations significatives

fan (V = 0.4486 - liaison forte) : c'est la relation la plus marquée. Sur 91 non-sportifs, 72 ne sont pas fans de sport (79 %). À l'inverse, sur 283 sportifs, 206 sont fans (73 %). La pratique sportive

et l'intérêt pour le sport en tant que spectateur vont clairement de pair. La contribution la plus forte au khi-deux vient de la cellule Non-sportif / Non-fan (35,2 sur un total de 77,4).

deptformation (V = 0.2035 - liaison modérée) : les étudiants en HSE sont 86 % à pratiquer du sport, contre 65 % en GEA et 78 % en SD. Les contributions montrent que l'écart vient surtout de GEA, où il y a plus de non-sportifs qu'attendu (contribution de 6,2), et de HSE, où il y en a moins qu'attendu (5,1). SD est proche de la moyenne générale et contribue très peu (0,2).

alimentation (V = 0.1921 - liaison modérée) : parmi les non-sportifs, la moitié ne fait pas attention à son alimentation (46 sur 91). Chez les sportifs, c'est l'inverse : 71 % déclarent y faire attention. La contribution dominante est la cellule Non-sportif / Ne fait pas attention (7,4) : les non-sportifs sont nettement plus nombreux que prévu dans cette catégorie.

sexe (V = 0.1886 - liaison modérée) : 81 % des hommes pratiquent un sport, contre 63 % des femmes. La contribution la plus élevée vient de la cellule Femme / Non-sportive (7,4) : il y a proportionnellement plus de femmes non-sportives que ce que l'on observerait si le sexe et le sport étaient indépendants.

reussite (V = 0.1855 - liaison modérée) : 67 % des sportifs sont « Tout à fait d'accord » avec l'idée que le sport aide à la réussite, contre 46 % des non-sportifs. Les non-sportifs se retrouvent davantage dans « Moyennement d'accord » (43 % vs 26 %). C'est cette cellule qui contribue le plus au khi-deux (5,2).

niveau (V = 0.1478 - liaison modérée) : en Licence Pro, 91 % des étudiants sont sportifs, contre 70 % en BUT1. Les contributions montrent que l'écart vient principalement des non-sportifs en Licence Pro (2,9, ils sont très peu nombreux par rapport à ce qu'on attendrait) et des non-sportifs en BUT1 (2,2) qui sont légèrement plus nombreux que prévu.

alternant (V = 0.1207 - liaison modérée) : 83 % des alternants sont sportifs, contre 72 % des non-alternants. La contribution la plus forte (3,0) vient de la cellule Non-sportif / Alternant : il y a moins d'alternants non-sportifs que prévu. Ce résultat peut s'expliquer par le fait que les alternants pratiquent majoritairement en dehors du SUAPS.

9.2 Relations non significatives

Les 6 variables suivantes ne présentent pas de relation significative avec la pratique sportive au seuil 5 % :

reprise (p = 1.00) : le fait d'être en reprise d'études ou non n'influence pas la pratique sportive. La p-valeur de 1 indique une indépendance quasi parfaite.

region (p = 0.16) : malgré le recodage en Poitou-Charentes vs Autre, l'origine géographique n'est pas significativement liée à la pratique sportive. Les étudiants locaux (73 % sportifs) et les étudiants venant d'ailleurs (80 % sportifs) ne présentent pas de différence suffisante pour être statistiquement significative.

bourse (p = 0.17) et travail (p = 0.72) : la situation financière (être boursier ou avoir un job étudiant) n'est pas significativement liée à la pratique sportive. Attention cependant, ces variables ne sont renseignées que pour les non-alternants (234 individus), ce qui réduit la puissance du test.

fumer (p = 0.54) : le fait de fumer n'est pas lié à la pratique sportive. 80 % des fumeurs pratiquent un sport, contre 76 % des non-fumeurs : la différence est trop faible pour être significative.

sante ($p = 0.58$) : la perception de sa santé comme bonne n'est pas significativement liée au sport. Toutefois, cette variable est très déséquilibrée (349 « Oui » vs 26 « Non »), ce qui limite la puissance du test et rend l'interprétation fragile.

10. Conclusion

L'analyse des 13 croisements entre la variable « sport » et les variables qualitatives du jeu de données a permis de mettre en évidence 7 relations significatives sur 13 tests effectués.

La liaison la plus forte est celle entre « sport » et « fan » ($V = 0.45$, liaison forte) : être fan de sport est très fortement associé à la pratique sportive. Les autres relations significatives sont de liaison modérée (V entre 0.12 et 0.20) : le département de formation, l'alimentation, le sexe, la perception de la réussite, le niveau d'études et le statut d'alternant.

En revanche, des variables comme la situation financière (bourse, travail), la région d'origine, le tabagisme, la santé perçue et la reprise d'études ne sont pas significativement liées à la pratique sportive. La variable logement a été exclue car ses effectifs théoriques ne respectaient pas les conditions de validité du khi-deux.

Il est important de noter que ces résultats décrivent des associations statistiques et non des liens de causalité. De plus, certaines variables présentent des limites (déséquilibre des effectifs pour « sante », effectifs réduits pour « bourse » et « travail » du fait des alternants).