

BUT Science des Données – Semestre 2
SAÉ – Régression sur des données réelles

Modélisation des prix immobiliers dans l'agglomération niortaise

DE MATHA Manon
ORANGE Simon

Année universitaire 2025–2026

1. Introduction

Ce projet porte sur la modélisation des prix immobiliers dans les communes de la Communauté d'Agglomération du Niortais. L'objectif est de construire un modèle de régression linéaire simple permettant de prédire le prix de vente d'un logement à partir de ses caractéristiques, puis d'appliquer ce modèle pour estimer les prix d'un jeu de données dont les valeurs foncières sont manquantes.

Le jeu d'entraînement mis à disposition contient 5 107 transactions immobilières (appartements et maisons) réalisées depuis 2021, réparties sur 42 communes de l'agglomération niortaise (département des Deux-Sèvres). Pour chaque transaction, les variables suivantes sont disponibles : la date de mutation, le code postal, la commune, le type de local (maison ou appartement), la surface réelle bâtie (en m²), le nombre de pièces principales, la surface du terrain (en m², souvent absente pour les appartements) et la valeur foncière (prix de vente en euros). C'est cette dernière variable que nous cherchons à prédire.

La démarche suivie repose sur trois étapes : l'exploration des données pour identifier des segments homogènes, la modélisation par régression linéaire simple pour chaque segment, et enfin la prédiction des prix manquants.

2. Exploration et segmentation

2.1. Distinction maisons et appartements

Nous avons d'abord exploré les données pour comprendre leur structure générale. Le jeu d'entraînement contient 4 038 maisons et 1 069 appartements. Les indicateurs statistiques de la valeur foncière révèlent deux marchés très distincts :

	MAISON		APPARTEMENT
Min	12000	Min	19049
Q1	119000	Q1	67553,08
Médiane	168000	Médiane	89500
Q3	228000	Q3	119900
Max	860000	Max	530000
Moyenne	180807,0	Moyenne	100116,8
Ecart type	93465,0	Ecart type	54596,7

Figures 1 et 2 – Indicateurs statistiques de la valeur foncière par type de logement

Les maisons présentent un prix médian de 168 000 € (moyenne 180 807 €) avec un écart type élevé de 93 465 €, tandis que les appartements affichent un prix médian de 89 500 € (moyenne 100 117 €) avec un écart type de 54 597 €. Les boîtes à moustaches ci-dessous confirment cette différence de distribution, avec une dispersion nettement plus importante pour les maisons et de nombreuses valeurs atypiques dans les deux cas.




Figure 3 – Boîtes à moustaches de la valeur foncière par type de logement

Par ailleurs, la variable surface terrain est quasi absente pour les appartements (99 % de valeurs manquantes), ce qui rend toute modélisation basée sur cette variable impossible pour ce type de bien. Cette première observation justifie une **séparation systématique entre maisons et appartements** comme premier axe de segmentation.

2.2. Choix de la variable explicative

Nous avons ensuite calculé les coefficients de corrélation linéaire entre la valeur foncière et trois variables explicatives potentielles : la surface bâtie, le nombre de pièces et la surface du terrain.




Figure 4 – Coefficients de corrélation linéaire avec la valeur foncière

La surface bâtie présente la corrélation la plus forte avec le prix, tant pour les appartements ($r = 0,717$) que pour les maisons ($r = 0,644$). Le nombre de pièces offre une corrélation légèrement inférieure (0,538 et 0,545). La surface terrain affiche une corrélation élevée pour les appartements (0,67), mais ce résultat n'est pas exploitable : seuls 12 appartements sur 1 069 disposent de cette donnée. Pour les maisons, la corrélation avec la surface terrain reste

faible (0,276). Nous avons donc retenu la **surface bâtie** comme variable explicative pour l'ensemble des modèles.

2.3. Segmentation géographique des maisons

Pour affiner la modélisation des maisons, nous avons initialement envisagé une séparation entre Niort et les autres communes. Cette approche donnait quatre sous-populations : maisons à Niort (1 897), maisons dans les agglomérations (2 141), appartements à Niort (998) et appartements hors Niort (71). Cependant, le segment des appartements hors Niort ne comptait que 71 observations avec un coefficient de corrélation de seulement 0,277 et un R^2 de 0,076, ce qui n'était pas exploitable. Nous avons donc décidé de conserver une seule population pour les appartements.

Pour les maisons, la séparation Niort/agglomérations donnait les résultats suivants : maisons à Niort ($r = 0,718$, $R^2 = 0,5157$, SCR = 8 633 milliards) et maisons dans les agglomérations ($r = 0,602$, $R^2 = 0,3622$, SCR = 11 128 milliards), soit une SCR totale de 19 761 milliards. Mais en calculant le prix au m² moyen par commune, nous avons constaté que Niort n'était pas la commune la plus chère : des communes périurbaines comme Bessines (2 191 €/m²), Chauray (2 099 €/m²) ou Échiré (2 036 €/m²) dépassaient Niort (1 970 €/m²). Isoler Niort seul revenait donc à séparer des communes au marché similaire.




Figure 5 – Prix au m² moyen par commune pour les maisons

Le graphique ci-dessus révèle un seuil naturel autour de 1 700 €/m², séparant deux groupes : les communes urbaines et périurbaines (Bessines, Chauray, Échiré, Vouillé, Niort, Magné, Aiffres, Saint-Gelais, Saint-Symphorien, Coulon, Saint-Maxire, Épannes, Saint-Rémy, La Crèche, Arcais, Sciecq, Le Bourdet et Granzay-Gript) et les communes plus rurales ou éloignées (les 24 communes restantes). Cette approche urbaine/rurale donne une SCR totale de 17 884 milliards (14 050 + 3 834), soit une amélioration de près de 1 900 milliards par rapport à l'approche Niort/agglomérations. Regrouper Niort avec ses communes périurbaines au marché immobilier similaire a davantage de sens économique que de l'isoler.

Segmentation finale retenue : trois segments : (1) Appartements (1 069 observations), (2) Maisons urbaines (18 communes, prix/m² ≥ 1 700 €), (3) Maisons rurales (24 communes restantes).

3. Modélisation

3.1. Appartements – Régression linéaire simple

Pour les appartements, le choix du modèle n'a pas été immédiat. Nous avons comparé un modèle linéaire et un modèle exponentiel. Le modèle exponentiel proposait un R^2 légèrement supérieur sur les données d'entraînement (0,5133 contre 0,5145). Cependant, l'évaluation sur le jeu de test a révélé une SCR plus faible pour le modèle linéaire (1 547 milliards contre 1 596 milliards, soit un écart de 49 milliards). Le modèle exponentiel s'ajuste mieux aux données d'entraînement mais généralise moins bien : il tend à surestimer les prix des grands appartements. Nous avons donc retenu le modèle linéaire pour sa meilleure capacité de généralisation.




Figure 6 – Régression linéaire de la valeur foncière en fonction de la surface des appartements

3.2. Maisons urbaines – Régression linéaire simple

Pour le segment des maisons urbaines (18 communes périurbaines), la régression linéaire simple donne un coefficient de corrélation de 0,710 et un R^2 de 0,5048. La SCR sur le jeu de test s'élève à 14 050 milliards.




Figure 7 – Régression linéaire de la valeur foncière en fonction de la surface des maisons urbaines

3.3. Maisons rurales – Régression linéaire simple

Le segment rural présente un coefficient de corrélation de 0,586 et un R^2 de 0,3439. Nous avons également testé des modèles logarithmique (SCR = 3 875 milliards) et puissance (SCR = 4 016 milliards), mais le modèle linéaire reste le meilleur avec une SCR de 3 834 milliards. Ce résultat, bien que surprenant, s'explique : la dispersion observée dans ce segment provient davantage de facteurs non capturés dans les données (l'état du bien, l'année de construction, l'attractivité locale) que d'une non-linéarité de la relation prix/surface.




Figure 8 – Régression linéaire de la valeur foncière en fonction de la surface des maisons rurales

3.4. Récapitulatif des modèles retenus

Le tableau ci-dessous synthétise les trois modèles de régression linéaire simple retenus pour chaque segment :

Segment	Variable	Équation	R ²	SCR (test)
Appartements (n = 1 069)	Surface bâtie	$y = 1\,827,4x + 2\,184,4$	0,5145	1 547 Mds
Maisons urbaines (n = 3 130)	Surface bâtie	$y = 1\,761,2x + 18\,262,9$	0,5048	14 050 Mds
Maisons rurales (n = 908)	Surface bâtie	$y = 1\,105,4x + 30\,500,8$	0,3439	3 834 Mds
				Total : 19 431 Mds

Tableau 1 – Récapitulatif des modèles de régression linéaire simple par segment

3.5. Évaluation du modèle sur le jeu de test

Afin de mesurer la capacité de généralisation de notre modèle, nous avons appliqué nos trois régressions linéaires au jeu de test contenant 1 596 logements. Le graphique ci-dessous compare les valeurs foncières réelles (classées par ordre décroissant) et les valeurs prédites par notre modèle :




Figure 9 – Évaluation de la performance du modèle sur les données de test

Les indicateurs de performance obtenus sur le jeu de test sont les suivants :

Indicateur	Valeur
Covariance (surface, valeur foncière)	2 417 546,13
Coefficient de corrélation linéaire (r)	0,650
Somme des carrés des résidus (SCR)	6 653 866 595 056
Somme des carrés totale (SCT)	13 117 941 225 439
Coefficient de détermination (R^2)	0,493

Tableau 2 – Indicateurs de performance du modèle sur le jeu de test (1 596 observations)

Le coefficient de détermination global de 0,493 signifie que notre modèle explique près de la moitié de la variance des prix immobiliers sur des données qu'il n'a jamais vues. On observe sur le graphique que les prédictions suivent bien la tendance générale des valeurs réelles, bien que certains pics dans les prédictions témoignent de biens dont le prix réel est très éloigné de ce que la surface seule permet de prédire.

4. Conclusion

La démarche adoptée nous a conduits à segmenter les données en trois populations homogènes et à appliquer un modèle de régression linéaire simple sur chacune, avec la surface bâtie comme unique variable explicative. Pour chaque segment, nous avons systématiquement testé plusieurs transformations (modèles exponentiel, puissance et logarithmique) et retenu le modèle offrant la meilleure somme des carrés des résidus sur le jeu de test. Le modèle linéaire l'emporte dans les trois cas, ce qui suggère une relation globalement proportionnelle entre surface et prix sur le marché niortais, sans effet d'accélération marqué.

La SCR totale de notre modèle s'élève à environ 19 431 milliards (1 547 + 14 050 + 3 834), ce qui représente une amélioration significative par rapport à une approche sans segmentation ou avec une segmentation naïve Niort/agglomérations (19 761 milliards).

Il convient toutefois de porter un regard critique sur ce modèle. Les R^2 obtenus, compris entre 0,34 et 0,51, montrent que la surface bâtie seule n'explique qu'environ la moitié de la variance des prix. De nombreux facteurs déterminants ne figurent pas dans les données : l'état général du bien, l'année de construction, la présence d'un garage ou d'une piscine, la proximité des commerces et transports, ou encore le diagnostic de performance énergétique (DPE). Le segment rural est particulièrement affecté, avec un R^2 de 0,34 reflétant l'hétérogénéité naturelle de ce marché où coexistent des corps de ferme rénovés et des pavillons récents. Une régression linéaire multiple, intégrant plusieurs variables explicatives simultanément, permettrait certainement d'améliorer la qualité des prédictions.